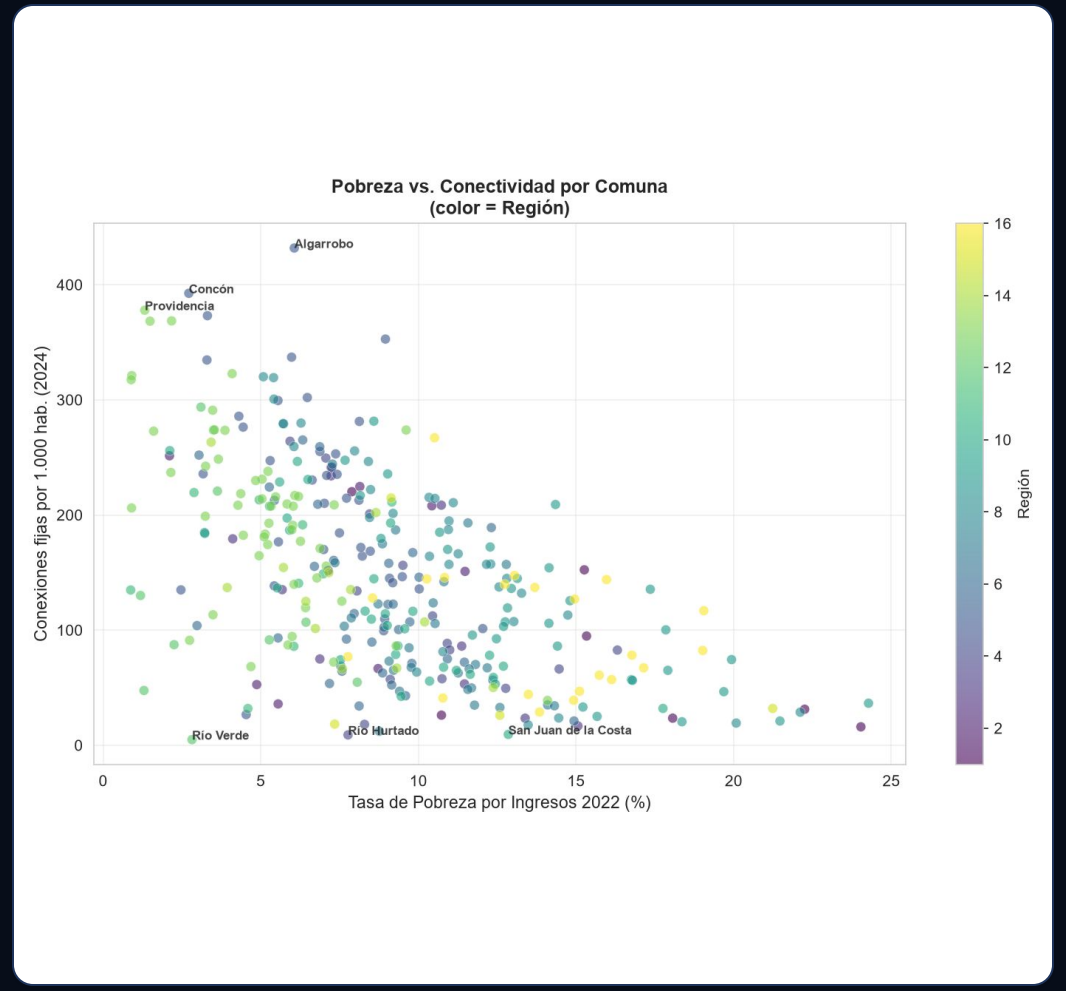
PROYECTO FINAL

Brecha Digital y Calidad de Red en Chile

Segmentación comunal y modelado predictivo mediante Machine Learning



Diego Lara · Cristóbal Castillo

Profesor: Jorge Rozas · Universidad Diego Portales · Data Science 2026

346 comunas analizadas

02

Problema y pregunta de investigación

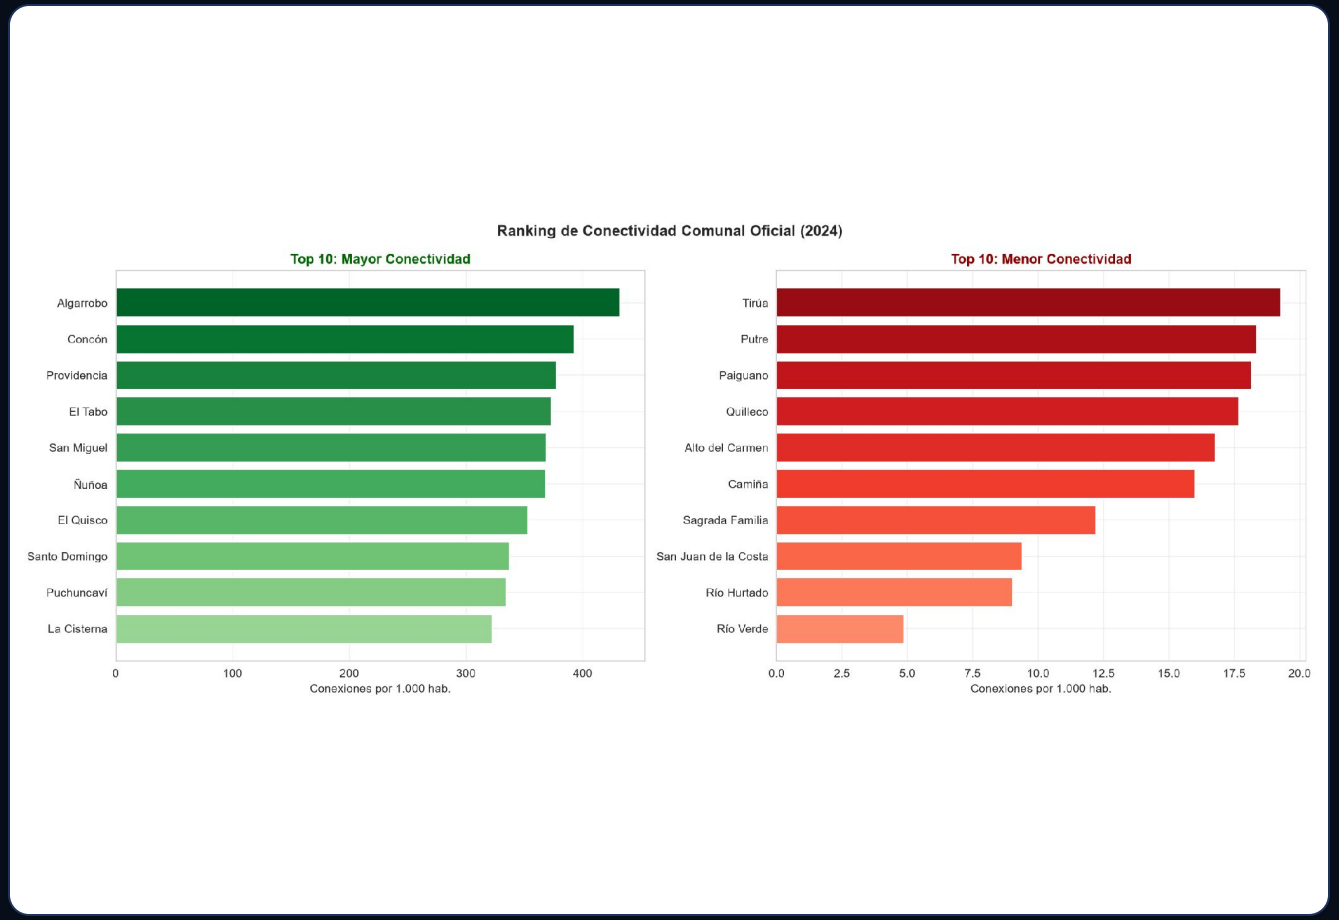
CONTEXTO

La conectividad habilita educación, salud, empleo y trámites públicos.

La brecha territorial separa a los grandes centros urbanos de comunas rurales y aisladas.

PREGUNTA CENTRAL

¿Qué factores socioeconómicos explican la brecha digital y permiten predecir la vulnerabilidad de una comuna?



Los extremos comunales muestran una diferencia territorial difícil de explicar con una sola variable.

03

Integración de fuentes oficiales

La conectividad se interpreta junto con población y vulnerabilidad socioeconómica

01	**SUBTEL**	Conexiones fijas por comuna	Infraestructura digital
02	**INE**	Proyecciones poblacionales 2024	Tasas comparables por 1.000 habitantes
03	**CASEN 2022**	Pobreza e ingreso comunal	Contexto socioeconómico

Resultado: una base comunal integrada para las 346 comunas oficiales de Chile

04

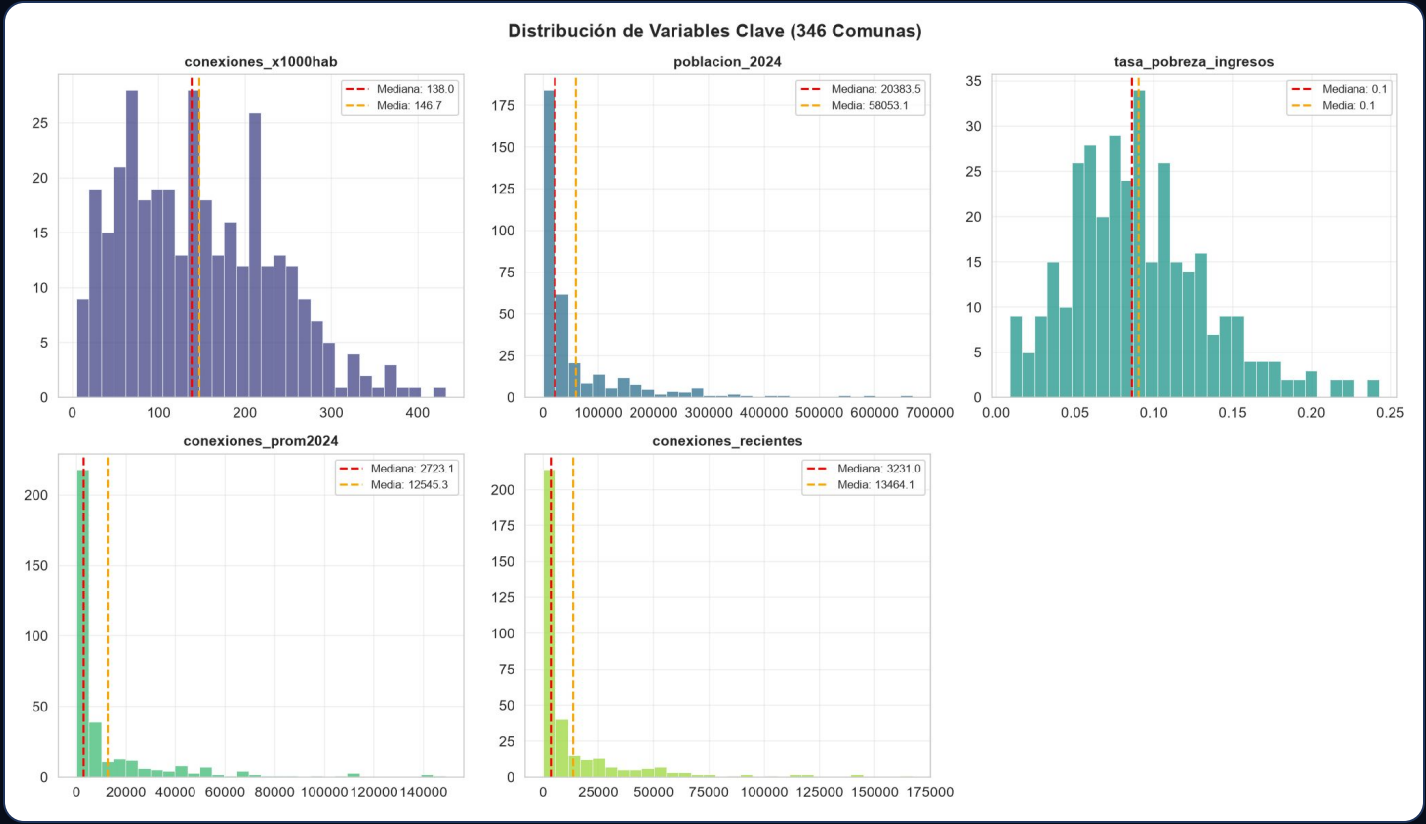
Limpieza y preparación de datos

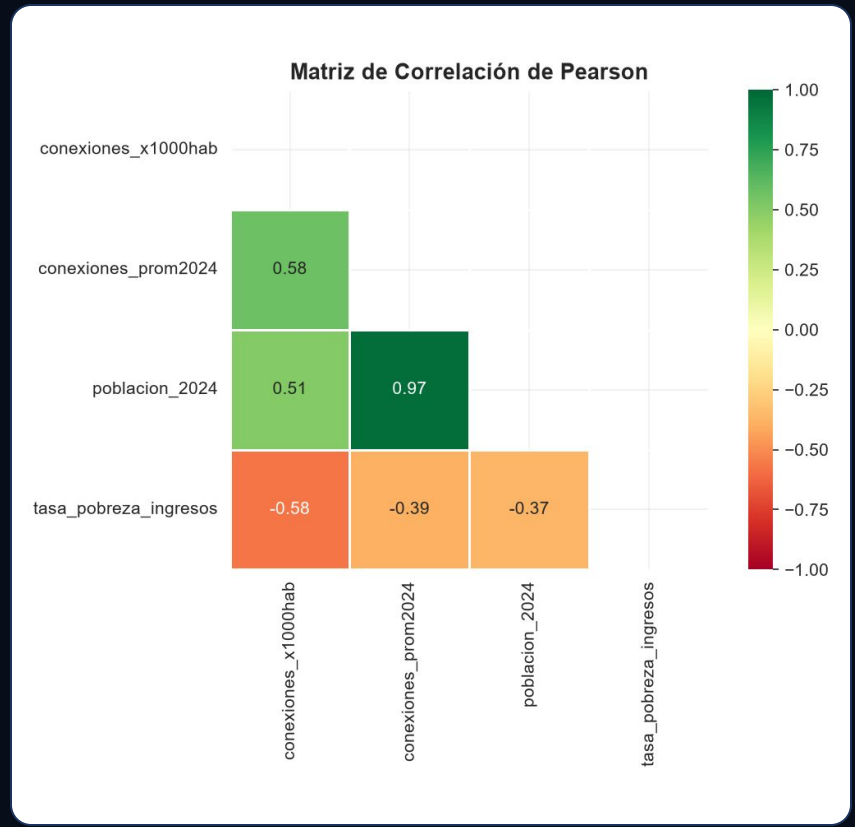
01	**Deduplicación territorial**	367 registros iniciales se redujeron a 346 comunas oficiales.
02	**Normalizar nombres**	Códigos CUT y nombres comunales homologados.
03	**Nulos y valores extremos**	Mediana regional y winsorización entre percentiles 1 y 99.
04	**Indicador comparable**	conexiones por 1.000 habitantes = conexiones / población × 1.000

Criterio de diseño: conservar comparabilidad sin eliminar comunas reales por su tamaño o aislamiento.

05

Análisis exploratorio de datos





−0,58

Correlación entre pobreza por ingresos y conexiones por 1.000 habitantes

0,58

Correlación entre conexiones totales y conexiones por 1.000 habitantes

346

Comunas incluidas en el análisis exploratorio

06

Segmentación comunal con K-Means

Aprendizaje no supervisado para descubrir perfiles sin etiquetas previas

1

Estandarización

Las variables se transforman a escala Z para hacerlas comparables.

2

Centroides

El algoritmo inicia centros de agrupación en el espacio multidimensional.

3

Asignación

Cada comuna se asocia al centroide más cercano mediante distancia euclidiana.

4

Convergencia

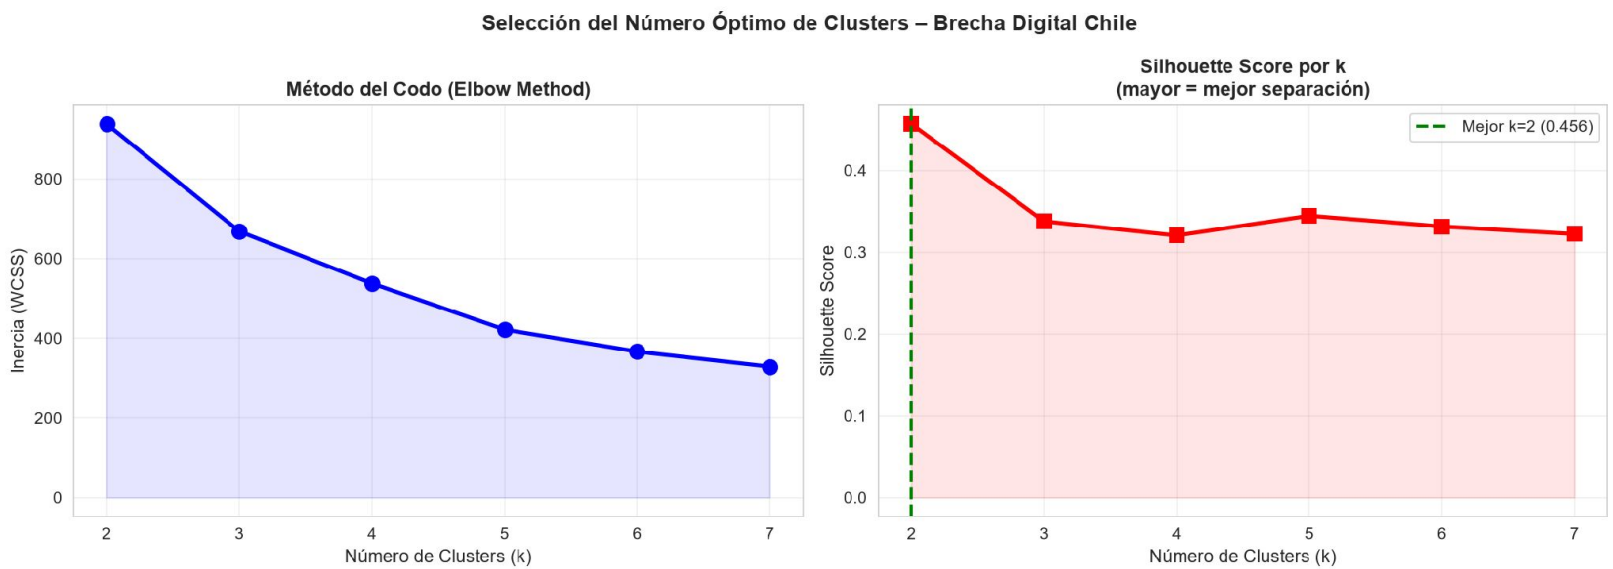
Los centroides se recalculan hasta estabilizar el error interno.

CRITERIO DE SELECCIÓN

Se compararon inercia y coeficiente de silueta para distintos valores de k.

07

Selección de tres perfiles de vulnerabilidad



0,456

Mayor silueta observada con k=2

0,338

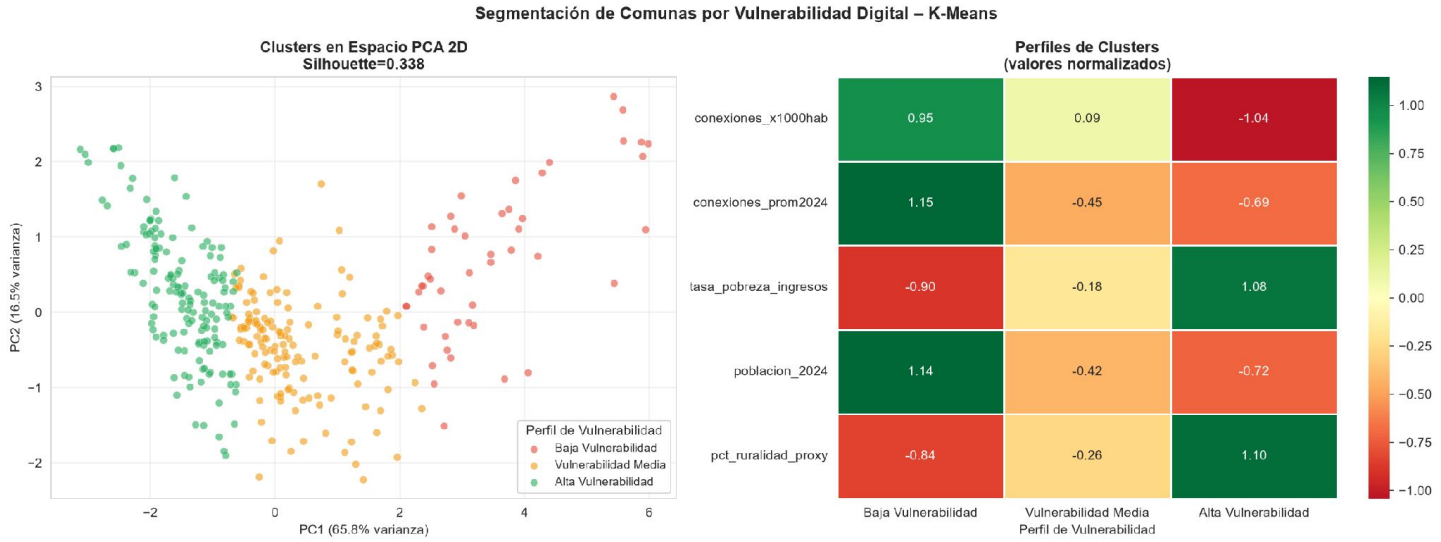
Silueta obtenida con k=3

k=3 conserva una separación razonable y permite distinguir vulnerabilidad alta, media y baja para fines de gestión.

Decisión metodológica: balance entre calidad estadística e interpretación para política pública.

08

Perfiles de vulnerabilidad digital



Perfil	N°	Conectividad
Alta vulnerabilidad	151	≈78 / 1.000
Vulnerabilidad media	148	≈180 / 1.000
Baja vulnerabilidad	47	≈258 / 1.000

43,6%

de las comunas pertenece al perfil de alta vulnerabilidad

09

Modelado predictivo supervisado

Las etiquetas de K-Means se convierten en el objetivo de clasificación

80%

Entrenamiento estratificado
276 comunas

20%

Prueba independiente
70 comunas

CONTROL DE FUGA DE DATOS

StandardScaler se ajusta únicamente con el conjunto de entrenamiento y luego transforma el conjunto de prueba.

MODELO BASE

Regresión logística multinomial

Modelo lineal e interpretable que estima la probabilidad de pertenecer a cada perfil.

MODELO NO LINEAL

Random Forest · 200 árboles

Ensamble capaz de capturar interacciones complejas entre conectividad, población, pobreza y ruralidad.

Cómo funcionan los modelos

REGRESIÓN LOGÍSTICA MULTINOMIAL

P(Y=k|X) = e^(β□ᵀX) / Σ e^(β□ᵀX)

La función Softmax transforma combinaciones lineales de las variables en probabilidades para cada perfil.

Fortaleza

Interpretación directa de la influencia de las variables.

Límite

Fronteras de decisión lineales.

RANDOM FOREST

200 árboles con subconjuntos aleatorios

Cada árbol divide el espacio mediante reglas. La clase final surge de la votación del conjunto.

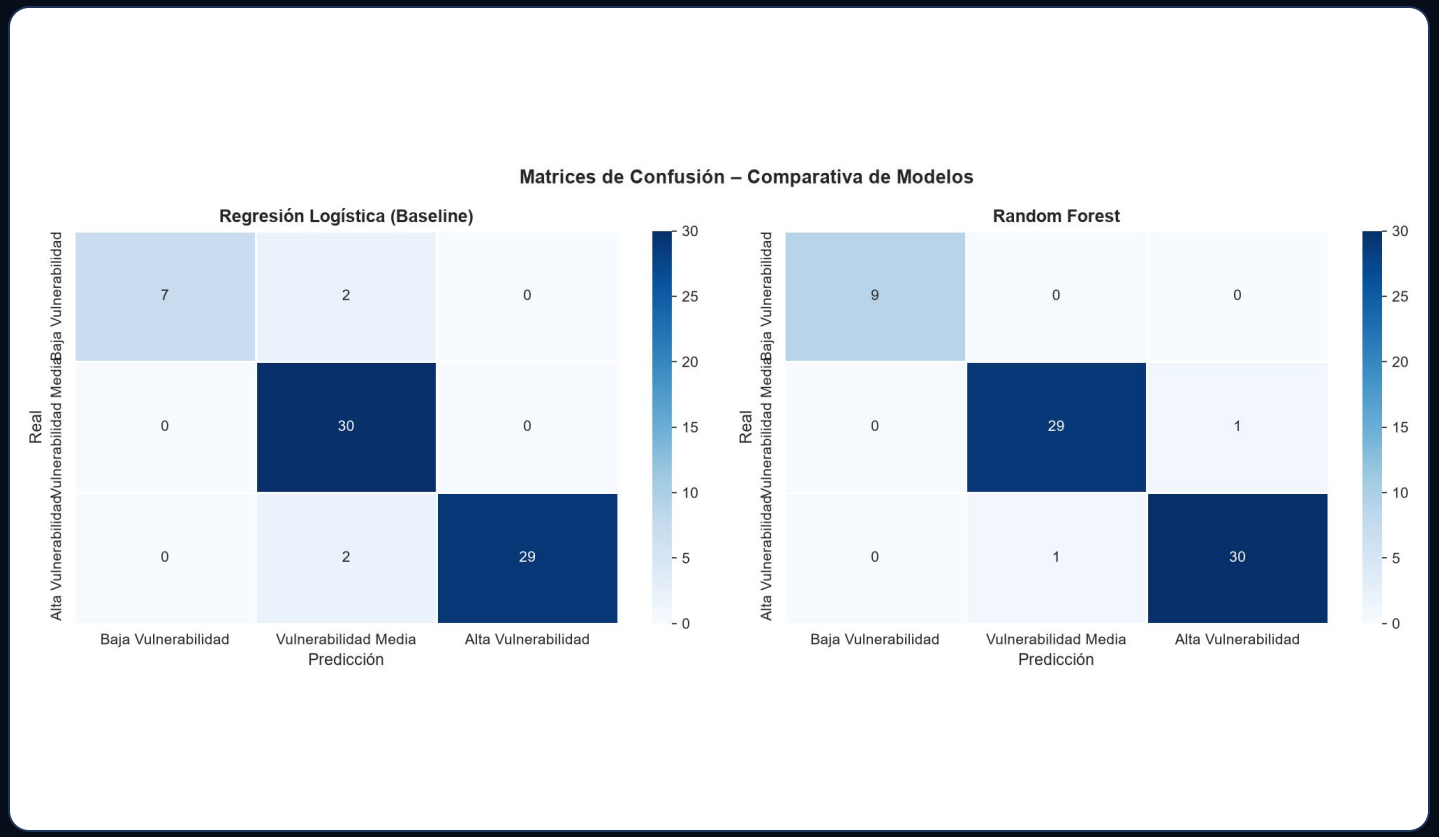
Fortaleza

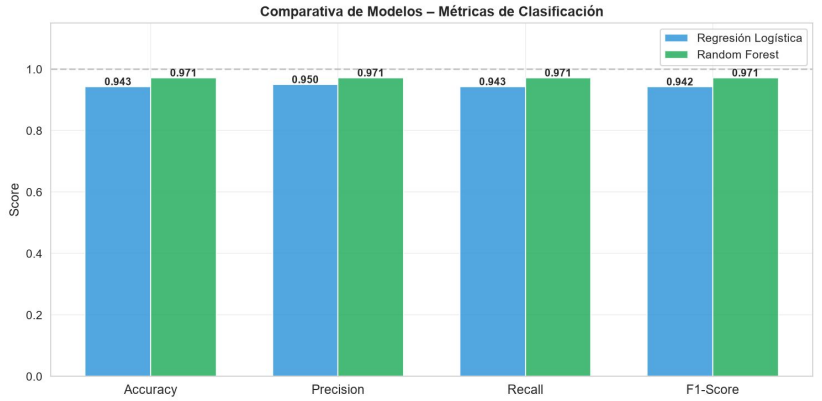
Captura interacciones y relaciones no lineales.

Costo

Menor transparencia que el modelo lineal.

Resultados de clasificación



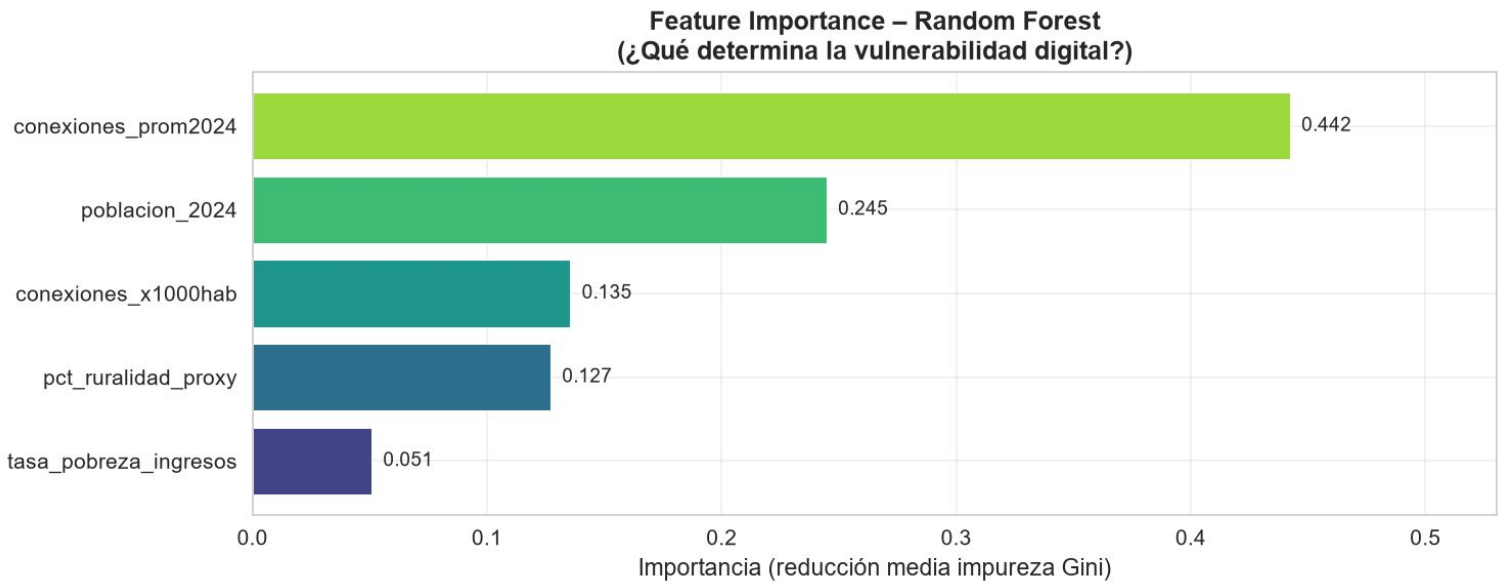


Modelo	Acc.	Prec.	Recall	F1
Reg. logística	0,943	0,950	0,943	0,942
Random Forest	**0,971**	**0,971**	**0,971**	**0,971**

2

errores de Random Forest en 70 comunas de prueba

Variables con mayor aporte predictivo



44,2% Conexiones promedio 2024

24,5% Población comunal

13,5% Conexiones por 1.000 hab.

12,7% Ruralidad aproximada

5,1% Pobreza por ingresos

La importancia refleja reducción media de impureza de Gini, no causalidad.

Conclusiones y recomendaciones de política pública

151
comunas en el perfil de alta vulnerabilidad

97,1%
accuracy del Random Forest en el conjunto de prueba

3
perfiles para focalización territorial

01

Infraestructura focalizada

Priorizar subsidios de última milla en las comunas de alta vulnerabilidad.

02

Tecnologías complementarias

Combinar fibra con conectividad satelital y móvil en zonas remotas.

03

Alfabetización digital

Acompañar la inversión técnica con capacitación para población vulnerable.